

Teoria da Decisão


Penalidades e Otimização Vetorial

Profa. Luiza Bernardes Real

luizabernardesreal@gmail.com


Universidade Federal de Minas Gerais
Escola de Engenharia
Graduação em Engenharia de Sistemas

Aula de hoje



O case será usado como fio condutor: a mesma composição de pilhas será vista primeiro como solução restrita e depois como solução multiobjetivo.

Visão geral do problema



O que eu quero decidir no case?

O que eu quero decidir no case?

Para cada minério $i \in \mathcal{I}$ e pilha $p \in \mathcal{P}$, defina:

x_{ip} = número de caminhões do minério i enviados à pilha p .

Domínio

$$x_{ip} \in \mathbb{Z}_+.$$

O que eu quero decidir no case?

Para cada minério $i \in \mathcal{I}$ e pilha $p \in \mathcal{P}$, defina:

x_{ip} = número de caminhões do minério i enviados à pilha p .

Domínio

$$x_{ip} \in \mathbb{Z}_+.$$

Como cada caminhão transporta 2 kt, a escolha da variável já garante que toda quantidade enviada é múltipla de 2 kt.

A mesma decisão possui várias consequências


Dada uma composição $\mathbf{x}$, podemos calcular:

- o custo total de aquisição;
- a massa de cada pilha;
- o teor de SiO_2 de cada pilha;
- o teor de Al_2O_3 de cada pilha;
- o uso total de cada minério;
- os desvios em relação aos alvos de qualidade.

Ideia central

Uma solução é uma decisão no espaço das variáveis; seus desempenhos formam um ponto no espaço dos objetivos.

Da composição das pilhas ao desempenho observado



Interpretação

A função $\mathbf{f}$ leva cada decisão aos seus resultados; as cores e letras ligam os dois espaços.

Projeção bidimensional ilustrativa: as demais variáveis e objetivos foram omitidos.

Massa e qualidade: passo a passo

Seja $c = 2$ kt a capacidade de um caminhão. A massa da pilha p é:

Massa e qualidade: passo a passo

Seja $c = 2$ kt a capacidade de um caminhão. A massa da pilha p é:

$$M_p(\mathbf{x}) = c \sum_{i \in \mathcal{I}} x_{ip}.$$

Se a_{ik} é o teor do atributo k no minério i , então:

Massa e qualidade: passo a passo

Seja $c = 2$ kt a capacidade de um caminhão. A massa da pilha p é:

$$M_p(\mathbf{x}) = c \sum_{i \in \mathcal{I}} x_{ip}.$$

Se a_{ik} é o teor do atributo k no minério i , então:

$$q_{pk}(\mathbf{x}) = \frac{\sum_{i \in \mathcal{I}} c a_{ik} x_{ip}}{M_p(\mathbf{x})}.$$

Massa e qualidade: passo a passo

Seja $c = 2$ kt a capacidade de um caminhão. A massa da pilha p é:

$$M_p(\mathbf{x}) = c \sum_{i \in \mathcal{I}} x_{ip}.$$

Se a_{ik} é o teor do atributo k no minério i , então:

$$q_{pk}(\mathbf{x}) = \frac{\sum_{i \in \mathcal{I}} c a_{ik} x_{ip}}{M_p(\mathbf{x})}.$$

Como todos os caminhões têm a mesma massa:

$$q_{pk}(\mathbf{x}) = \frac{\sum_i a_{ik} x_{ip}}{\sum_i x_{ip}}.$$

As restrições separam o aceitável do inaceitável

Para uma pilha p do grupo $s(p)$:

$$M_p(\mathbf{x}) = \overline{M}_p,$$

$$L_{s(p),k} \leq q_{pk}(\mathbf{x}) \leq U_{s(p),k}, \quad k \in \{\text{SiO}_2, \text{Al}_2\text{O}_3\}.$$

Para cada minério i :

$$d_i^{\min} \leq \sum_{p \in \mathcal{P}} x_{ip} \leq d_i^{\max}.$$

Compatibilidades minério–equipamento podem ser representadas impondo $x_{ip} = 0$ nos pares não permitidos.

Viável não significa boa; boa não significa viável

Solução viável

Satisfaz todas as restrições. Pode, ainda assim, ser muito cara ou apresentar grandes desvios em relação aos alvos.

Solução atraente, mas inviável


Pode ter baixo custo e boa qualidade média, mas exceder a disponibilidade de um minério ou violar uma faixa em uma pilha.

Na GVNS


Rejeitar toda solução inviável pode impedir a busca de atravessar uma região inviável para alcançar outra região viável e melhor.

Dois obstáculos podem aprisionar a busca

1. Um ótimo local



2. Uma barreira de factibilidade



Ideias diferentes, que podem atuar juntas

A **perturbação** combate ótimos locais. A **penalização** remove barreiras de factibilidade. Aceitar inviáveis só ajuda a escapar de um ótimo local quando uma região inviável separa a solução atual de uma região melhor.

Duas considerações sobre soluções inviáveis

1. Eliminar toda solução inviável pode ser ineficiente

Estratégias rudimentares usualmente descartam soluções inviáveis. Embora simples, elas não asseguram eficácia nem eficiência. Em problemas difíceis, encontrar até mesmo uma primeira solução viável pode exigir grande esforço.

2. A fronteira da região viável merece atenção

Em muitos problemas, a solução ótima está na fronteira da região viável. Permitir a evolução controlada de soluções nos dois lados dessa fronteira pode favorecer a convergência para o ótimo.

Consequência para o projeto do algoritmo

Em vez de apenas descartar, podemos penalizar, reparar ou criar operadores inteligentes que explorem as proximidades da fronteira.

Primeiro degrau: transformar uma restrição em violação

Considere uma desigualdade escrita como:

$$g(\mathbf{x}) \leq 0.$$

Sua violação positiva pode ser definida por:

$$v_g(\mathbf{x}) = \max\{0, g(\mathbf{x})\}.$$

- Se $g(\mathbf{x}) \leq 0$, então $v_g(\mathbf{x}) = 0$.
- Se $g(\mathbf{x}) > 0$, então $v_g(\mathbf{x}) = g(\mathbf{x})$.

A função $\max\{0, \cdot\}$ ignora a folga viável e mede apenas o excesso.

Limite superior e limite inferior

Para a faixa $L \leq q(\mathbf{x}) \leq U$, existem duas desigualdades:

$$q(\mathbf{x}) - U \leq 0, \quad L - q(\mathbf{x}) \leq 0.$$

Logo, as violações são:

$$v^+(\mathbf{x}) = \max\{0, q(\mathbf{x}) - U\},$$

$$v^-(\mathbf{x}) = \max\{0, L - q(\mathbf{x})\}.$$

No case, cada pilha tem duas medidas desse tipo para SiO_2 e duas para Al_2O_3 .

Igualdades também podem ser violadas

Para uma igualdade:

$$h(\mathbf{x}) = 0,$$

podemos usar:

$$v_h(\mathbf{x}) = |h(\mathbf{x})| \quad \text{ou} \quad v_h^2(\mathbf{x}) = [h(\mathbf{x})]^2.$$

No case, o desvio da massa da pilha p em relação à massa desejada pode ser escrito como:

$$h_p(\mathbf{x}) = M_p(\mathbf{x}) - \overline{M}_p = 0.$$

A representação por posições pode preservar essa igualdade automaticamente; nesse caso, não precisamos penalizá-la.

Exemplo resolvido: uma pilha fora da faixa

Para o Sinter 1, considere a faixa de SiO_2 :

$$5,0\% \leq q_{p,\text{SiO}_2} \leq 6,2\%.$$

Uma composição produz $q_{p,\text{SiO}_2} = 6,4\%$.

Exemplo resolvido: uma pilha fora da faixa

Para o Sinter 1, considere a faixa de SiO_2 :

$$5,0\% \leq q_{p,\text{SiO}_2} \leq 6,2\%.$$

Uma composição produz $q_{p,\text{SiO}_2} = 6,4\%$.

$$v^+ = \max\{0, 6,4 - 6,2\} = 0,2,$$

$$v^- = \max\{0, 5,0 - 6,4\} = 0.$$

A solução excede somente o limite superior, em 0,2 ponto percentual.

Sua vez: calcule a violação

Para o Sinter 2, a faixa de Al_2O_3 é:

$$1,0\% \leq q_{p,\text{Al}_2\text{O}_3} \leq 2,2\%.$$

Considere três pilhas:

$$q_A = 0,8\%, \quad q_B = 1,7\%, \quad q_C = 2,5\%.$$

Sua vez!

Para cada pilha, calcule v^- e v^+ . Qual é viável?

Conferindo o cálculo

Pilha	q	$v^- = \max\{0, 1,0 - q\}$	$v^+ = \max\{0, q - 2,2\}$	Situação
A	0,8%	0,2	0,0	Inviável
B	1,7%	0,0	0,0	Viável
C	2,5%	0,0	0,3	Inviável

Interpretação

A medida de violação informa não apenas se a restrição foi violada, mas também a distância até a faixa admissível.

Somar violações exige cuidado com a escala

Não é coerente somar diretamente:

2 kt de falta de massa + 0,2 ponto percentual de SiO_2 + 3 caminhões excedentes.

Uma opção é normalizar cada violação por uma escala relevante:

$$\hat{v}_r(\mathbf{x}) = \frac{v_r(\mathbf{x})}{s_r},$$

em que $s_r > 0$ representa, por exemplo, a massa-alvo, a largura da faixa ou a disponibilidade máxima.

Sem normalização, a unidade numericamente maior pode dominar a penalidade.

Uma medida agregada para o case

Uma possibilidade é:

$$V(\mathbf{x}) = \sum_{r \in \mathcal{R}} w_r [\hat{v}_r(\mathbf{x})]^2, \quad w_r \geq 0.$$

- $V(\mathbf{x}) = 0$ se todas as restrições consideradas forem satisfeitas;
- $V(\mathbf{x}) > 0$ se pelo menos uma delas for violada;
- o quadrado aumenta a importância de violações grandes;
- w_r permite diferenciar famílias de restrições.

As escolhas de escala e peso fazem parte do algoritmo e precisam ser justificadas.

Segundo degrau: incorporar a violação ao objetivo

Considere o problema restrito:

$$\min_{\mathbf{x} \in \mathcal{F}} f(\mathbf{x}).$$


Um método de penalidade exterior usa a função ampliada:

$$F(\mathbf{x}; \lambda) = f(\mathbf{x}) + \lambda V(\mathbf{x}), \quad \lambda > 0.$$

Interpretação

f recompensa desempenho; V cobra pelas violações; λ determina quanto essa cobrança pesa na comparação.

A busca pode se beneficiar dos dois lados da fronteira



Interpretação

Caminhos diferentes podem se aproximar do mesmo ótimo de fronteira. A inviabilidade só deve ser explorada de modo controlado e temporário.



Por que “penalidade exterior”?

- Soluções fora da região viável podem ser avaliadas.
- Quanto maior a violação, maior o acréscimo na função ampliada.
- Ao aumentar λ , a busca recebe um incentivo crescente para se aproximar da região viável.

Não confundir

A penalidade não torna uma solução viável. Ela apenas altera a forma como soluções viáveis e inviáveis são comparadas.

Cada aumento de λ produz uma nova solução ótima



Interpretação das linhas amarelas

Para cada λ_k , a linha marca o mínimo da curva F_{λ_k} . Ao aumentar λ , esses mínimos se aproximam da solução restrita x^* .

Exemplo unidimensional: o problema original

Considere:

$$\begin{array}{ll} \min_x & f(x) = x \\ \text{sujeito a} & x \geq 3. \end{array}$$

Escrevendo a restrição como $g(x) = 3 - x \leq 0$:

$$V(x) = [\max\{0, 3 - x\}]^2.$$

A função penalizada é:

$$F(x; \lambda) = x + \lambda [\max\{0, 3 - x\}]^2.$$

Exemplo unidimensional: resolvendo por partes

Para $x \geq 3$, $V(x) = 0$ e $F(x; \lambda) = x$.

Para $x < 3$:

$$F(x; \lambda) = x + \lambda(3 - x)^2.$$

Derivando:

$$\frac{dF}{dx} = 1 - 2\lambda(3 - x) = 0,$$

obtemos:

$$x_{\lambda}^* = 3 - \frac{1}{2\lambda}.$$

Quando $\lambda \rightarrow \infty$, $x_{\lambda}^* \rightarrow 3$ pelo lado inviável.

O parâmetro muda o comportamento da busca

λ	x_λ^*	Violação 3 – x_λ^*	$f(x_\lambda^*)$
1	2,500	0,500	2,500
10	2,950	0,050	2,950
100	2,995	0,005	2,995

Efeito sobre a solução penalizada

Quanto maior λ , maior o custo da inviabilidade. O minimizador de F_λ se aproxima da solução restrita e a violação diminui.

Penalidade excessiva pode bloquear a exploração

Considere uma busca que aceita movimentos de melhoria segundo

$$F(\mathbf{x}; \lambda) = f(\mathbf{x}) + \lambda V(\mathbf{x}).$$

Para alcançar a solução viável C, a busca precisa passar temporariamente pela solução inviável B.

Solução	$f(\mathbf{x})$	$V(\mathbf{x})$
A: viável atual	100	0,00
B: passagem inviável	80	0,05
C: viável melhor	60	0,00

Penalidade menor: $\lambda = 100$

$$F(A) = 100, \quad F(B) = 80 + 100(0,05) = 85.$$

A busca pode alcançar a região viável que contém C.

Penalidade elevada: $\lambda = 1000$

$$F(A) = 100, \quad F(B) = 80 + 1000(0,05) = 130.$$

Não é possível alcançar C.

Quanto maior λ , menor a tolerância à inviabilidade; porém, menor pode ser a capacidade de atravessar regiões inviáveis.

Penalidade estática ou dinâmica?

Estática

$$F(\mathbf{x}) = f(\mathbf{x}) + \lambda V(\mathbf{x}).$$

O mesmo λ é usado durante toda a busca.

Dinâmica

$$F_k(\mathbf{x}) = f(\mathbf{x}) + \lambda_k V(\mathbf{x}).$$

O peso muda com a iteração, por exemplo $\lambda_{k+1} = \alpha \lambda_k$, com $\alpha > 1$.

No início, a busca explora; depois, a pressão por viabilidade aumenta.

A penalidade é uma política; existem outras

Política	Ideia
Rejeição	O vizinho inviável nunca é aceito.
Reparo	Um procedimento tenta corrigir o vizinho.
Operador viável	A vizinhança é construída para preservar restrições.
Regras de factibilidade	Viável vence inviável; entre inviáveis, vence a menor violação.
Penalidade	Objetivo e violação são agregados em uma função ampliada.

Terceiro degrau: um único número não conta toda a história

Problemas de otimização vetorial, ou multiobjetivo, pertencem à classe de **tomada de decisão multiobjetivo** (MODM):

No case, queremos minimizar simultaneamente:

$$\mathbf{f}(\mathbf{x}) = \begin{bmatrix} f_1(\mathbf{x}) \\ f_2(\mathbf{x}) \\ f_3(\mathbf{x}) \end{bmatrix} = \begin{bmatrix} \text{custo total} \\ \text{soma dos desvios quadráticos de SiO}_2 \\ \text{soma dos desvios quadráticos de Al}_2\text{O}_3 \end{bmatrix}.$$

A função objetivo agora é vetorial: $\mathbf{f} : \mathcal{F} \rightarrow \mathbb{R}^3$. Metodologicamente, otimizamos um vetor; do ponto de vista do decisor, procuramos uma ação que concilie todas as consequências relevantes.

Formulação geral de um problema multiobjetivo

$$\begin{array}{ll}\min_{\mathbf{x}} & \mathbf{f}(\mathbf{x}) = (f_1(\mathbf{x}), \dots, f_m(\mathbf{x})) \\ \text{sujeito a} & g_i(\mathbf{x}) \leq 0, \quad i = 1, \dots, r, \\ & h_j(\mathbf{x}) = 0, \quad j = 1, \dots, s, \\ & \mathbf{x} \in \mathcal{X}.\end{array}$$

Diferença fundamental

A modelagem fica mais flexível e realista, mas essa flexibilidade tem um preço: em geral, não existe uma única solução que minimize todos os objetivos. Obtemos um conjunto de soluções de compromisso.

A otimização organiza as alternativas eficientes; a escolha final entre elas pertence à unidade de decisão.

Espaço de decisão e espaço de objetivos

Espaço de decisão

Cada ponto $\mathbf{x}$ descreve a composição das 10 pilhas: quantos caminhões de cada minério vão para cada pilha.




Espaço de objetivos


Cada ponto $\mathbf{y} = \mathbf{f}(\mathbf{x})$ informa custo, desvio de SiO_2 e desvio de Al_2O_3 .

Duas composições diferentes podem produzir desempenhos muito próximos; uma mesma composição produz um único vetor de desempenho.

Cada objetivo pode apontar para uma decisão diferente



No espaço dos objetivos surge uma fronteira de compromissos



Por que os objetivos são conflitantes no case?

- Minérios mais baratos podem apresentar teores mais distantes dos alvos.
- Aproximar SiO_2 do alvo pode afastar Al_2O_3 .

Consequência

“Minimizar custo e desvios” não define, sozinho, uma única resposta. Falta dizer quais trocas são aceitáveis.

Duas perguntas guiam o restante da aula: como definir as soluções de um problema multiobjetivo? Como compará-las e ordená-las?

Comparação componente a componente


Dominância Pareto

Seja $\mathbf{x}_1, \mathbf{x}_2 \in \mathcal{F}$, dizemos que $\mathbf{x}_1$ Pareto domina (ou, simplesmente, domina) $\mathbf{x}_2$ se $f_k(\mathbf{x}_1) \leq f_k(\mathbf{x}_2) \forall k \in \{1, \dots, m\}$ e $\exists k$ tal que $f_k(\mathbf{x}_1) < f_k(\mathbf{x}_2)$, ou seja, em pelo menos um dos objetivos a desigualdade é atendida de forma estrita. Esta relação de dominância é escrita como $\mathbf{f}(\mathbf{x}_1) \prec \mathbf{f}(\mathbf{x}_2)$.

Soluções incomparáveis

Seja $\mathbf{x}_1, \mathbf{x}_2 \in \mathcal{F}$, dizemos que os mesmos são não dominados entre si, ou incomparáveis entre si, se $\mathbf{f}(\mathbf{x}_1) \not\prec \mathbf{f}(\mathbf{x}_2)$ e $\mathbf{f}(\mathbf{x}_2) \not\prec \mathbf{f}(\mathbf{x}_1)$.

Dominância e incomparabilidade no espaço dos objetivos



Exemplo resolvido com três objetivos

Todos os valores estão normalizados e devem ser minimizados:

$$\mathbf{f}(A) = (0,35, 0,30, 0,40),$$

$$\mathbf{f}(B) = (0,40, 0,45, 0,50).$$

Comparando:

$$0,35 < 0,40, \quad 0,30 < 0,45, \quad 0,40 < 0,50.$$

A é melhor nos três objetivos. Portanto, A domina B .

Exemplo resolvido: soluções incomparáveis

Considere:

$$\mathbf{f}(C) = (0,20, 0,50, 0,55), \quad \mathbf{f}(D) = (0,35, 0,30, 0,40).$$

- C é melhor em custo: $0,20 < 0,35$;
- D é melhor nos dois desvios: $0,30 < 0,50$ e $0,40 < 0,55$.

Nenhuma domina a outra. Escolher entre C e D exige informação de preferência.

Sua vez: encontre a solução dominada

Todos os objetivos devem ser minimizados.

Solução	Custo f_1	Desvio SiO_2 f_2	Desvio Al_2O_3 f_3
A	0,10	0,80	0,60
B	0,20	0,50	0,55
C	0,35	0,30	0,40
D	0,40	0,45	0,50
E	0,65	0,20	0,25
F	0,80	0,25	0,15

Pergunta

Qual solução pode ser eliminada sem conhecer as preferências do decisor? Quem a domina?

Conferindo a dominância

A solução D é dominada por C:

$$0,35 < 0,40, \quad 0,30 < 0,45, \quad 0,40 < 0,50.$$

Portanto, não existe razão para escolher D quando C está disponível.

As soluções A, B, C, E e F são incomparáveis entre si neste conjunto: melhorar um componente exige piorar pelo menos outro.

Conjunto Pareto-ótimo

Dado um problema de otimização multiobjetivo, o seu conjunto Pareto-ótimo global é definido como:

$$\mathcal{P}^* = \{\mathbf{x}^* \in \mathcal{F} \mid \nexists \mathbf{x} \in \mathcal{F} \text{ tal que } \mathbf{f}(\mathbf{x}) \prec \mathbf{f}(\mathbf{x}^*)\}$$

O conjunto Pareto-ótimo contém as soluções não dominadas em relação ao conjunto $\mathcal{F}$.

Este conjunto é também nomeado *não-inferior*, *eficiente*, ou *não-dominado*.

Fronteira de Pareto


Definição

A fronteira Pareto-ótima global é a imagem do conjunto Pareto-ótimo $\mathcal{P}^*$ no espaço dos objetivos:

$$\mathcal{Y}^* = \mathbf{f}(\mathcal{P}^*) = \{\mathbf{y} = \mathbf{f}(\mathbf{x}) : \mathbf{x} \in \mathcal{P}^*\}.$$

- $\mathcal{P}^*$ pertence ao espaço de decisões e contém composições eficientes de pilhas;
- $\mathcal{Y}^*$ pertence ao espaço dos objetivos e contém os vetores de custo e qualidade dessas composições;
- a cardinalidade de $\mathcal{P}^*$ e de $\mathcal{Y}^*$ pode ser muito elevada ou até infinita;
- na prática, buscamos conjuntos finitos que representem adequadamente tanto $\mathcal{P}^*$ quanto $\mathcal{Y}^*$.

O conjunto Pareto-ótimo gera a fronteira de Pareto



A mesma eficiência vista em dois espaços

$\mathcal{P}^*$ contém decisões eficientes; $\mathcal{Y}^*$ contém seus desempenhos. É a função vetorial f que liga os dois conjuntos.

Na prática, obtemos uma aproximação

Conjunto Pareto-ótimo aproximado

Quando não podemos determinar exatamente o conjunto Pareto-ótimo global, trabalhamos com uma estimativa $\tilde{\mathcal{P}}$. Em problemas reais, essa estimativa normalmente contém um número finito de soluções não dominadas encontradas pelo algoritmo:

$$\tilde{\mathcal{P}} \subseteq \mathcal{F}.$$

Fronteira Pareto-ótima aproximada



A imagem dessas decisões no espaço dos objetivos é

$$\tilde{\mathcal{Y}} = \mathbf{f}(\tilde{\mathcal{P}}).$$

No case

A VNS/GVNS não entrega toda a fronteira verdadeira; ela entrega um conjunto limitado de composições que procura representar bem seus compromissos.

Uma boa aproximação deve cobrir a fronteira



Qualidade da aproximação

Em vermelho estão $\mathcal{P}^*$ e $\mathcal{Y}^*$; em azul, suas aproximações internas. Procuramos pouca distância até as curvas verdadeiras e boa distribuição dos pontos: **convergência** e **diversidade**.

Exemplo: encontre o conjunto Pareto-ótimo

Problema com uma variável e dois objetivos

$$\min_{x \geq 0} \begin{bmatrix} f_1(x) \\ f_2(x) \end{bmatrix} = \begin{bmatrix} x - 1 \\ (x - 3)^2 + 1 \end{bmatrix}, \quad x \in \mathbb{R}.$$


- f_1 cresce com x e, isoladamente, é minimizada em $x = 0$.
- f_2 diminui até $x = 3$ e, isoladamente, é minimizada em $x = 3$.
- Entre 0 e 3, melhorar um objetivo piora o outro.
- Para $x > 3$, ambos os objetivos pioram em relação a $x = 3$.

Pergunta


Esboce as soluções eficientes nos espaços de decisão e dos objetivos.

Resposta gráfica: decisões e desempenhos eficientes

Espaço de decisão $\mathbb{R}^n$



Espaço objetivo $\mathbb{R}^m$



Pareto elimina soluções ruins, mas não escolhe sozinho

A dominância permite afirmar:

- “D não deve ser escolhida, pois C é melhor em tudo.”

Mas não permite afirmar, sem preferências:

- “A é melhor que C”, quando A é mais barata e C tem menores desvios;
- “o custo compensa o aumento de SiO_2 ”;
- “um pequeno ganho em Al_2O_3 vale uma grande piora em custo”.

Pareto organiza as alternativas; o decisor escolhe entre os compromissos eficientes.

Algoritmo de ordenação por dominância Pareto

Algorithm 1: Ordenação Pareto

```
1  $N' = N$ ; currentRank  $\leftarrow$  1;
2 while  $N \neq \emptyset$  do
    /* Há pontos a serem classificados */
3   for  $i = 1$  to  $|N'|$  do
4     if  $y_i$  é não dominado then rank( $y_i$ )  $\leftarrow$  currentRank;
5   end
6   for  $i = 1$  to  $|N'|$  do
7     if rank( $y_i$ ) = currentRank then
8       Armazena  $y_i$  em um conjunto temporário;
9        $N \leftarrow N \setminus \{y_i\}$ ;
10    end
11  end
12  currentRank  $\leftarrow$  currentRank + 1;  $N' \leftarrow N$ ;
13 end
```

Ordenação Pareto — Exemplo ($\min f_1$, $\min f_2$)

Aplicamos o algoritmo de Ordenação Pareto ao conjunto abaixo, minimizando f_1 e f_2 .

Solução	f_1	f_2
A	8	5
B	9	2
C	12	1
D	11	2
E	16	2

Inicialização:

- $N \leftarrow \{A, B, C, D, E\}$
- $N' \leftarrow N$
- $\text{currentRank} \leftarrow 1$

Regra de dominância: $\mathbf{y}^{(i)}$ domina $\mathbf{y}^{(j)}$ se $f_1^{(i)} \leq f_1^{(j)}$ e $f_2^{(i)} \leq f_2^{(j)}$, com pelo menos uma desigualdade estrita.

Iteração 1 — Verificação de dominância ($N' = \{A, B, C, D, E\}$)

Para cada solução, verificamos se existe alguma outra que a domina:

Sol.	f_1	f_2	Análise	Dominado por
A	8	5	Nenhuma tem $f_1 \leq 8$ e $f_2 \leq 5$ estritamente	—
B	9	2	A: $f_1=8 < 9$ mas $f_2=5 > 2$; demais têm $f_1 > 9$	—
C	12	1	B: $f_1=9 < 12$ mas $f_2=2 > 1$; A: $f_2=5 > 1$	—
D	11	2	B: $f_1=9 < 11$ e $f_2=2 \leq 2$ (f_1 estritamente menor)	B
E	16	2	B: $f_1=9 < 16$ e $f_2=2 \leq 2$ (f_1 estritamente menor)	B

Resultado: soluções não dominadas $\Rightarrow \text{rank}(A) = \text{rank}(B) = \text{rank}(C) = 1$

$N \leftarrow N \setminus \{A, B, C\} = \{D, E\}$; $\text{currentRank} \leftarrow 2$; $N' \leftarrow \{D, E\}$

Iteração 2 — Verificação de dominância ($N' = \{D, E\}$)

Repetimos o laço apenas sobre as soluções restantes:

Sol.	f_1	f_2	Análise	Dominado por
D	11	2	E: $f_1=16 > 11$ — não domina D	—
E	16	2	D: $f_1=11 < 16$ e $f_2=2 \leq 2$ (f_1 estritamente menor)	D

Resultado: D não é dominado $\Rightarrow \text{rank}(D) = 2$

$N \leftarrow N \setminus \{D\} = \{E\}$; `currentRank` $\leftarrow 3$; $N' \leftarrow \{E\}$

Iteração 3 — Verificação de dominância ($N' = \{E\}$)

Apenas uma solução restante — nenhum comparador disponível:

Sol.	f_1	f_2	Análise	Dominado por
E	16	2	Único elemento em N' — não pode ser dominado	—


Resultado: $\text{rank}(E) = 3$

$N \leftarrow N \setminus \{E\} = \emptyset \Rightarrow$ algoritmo encerra.

Resultado Final — Ordenação Pareto

Sol.	f_1	f_2	Rank
A	8	5	1
B	9	2	1
C	12	1	1
D	11	2	2
E	16	2	3

- **Rank 1** (Fronteira Pareto): $\{A, B, C\}$
- **Rank 2:** $\{D\}$
- **Rank 3:** $\{E\}$



Dois pontos de referência resumem os extremos da fronteira

Ponto ideal ou solução utópica

Cada coordenada é o melhor valor isolado do objetivo correspondente:

$$u_j = \min\{y_j : \mathbf{y} \in \mathcal{Y}^*\} = f_j(\mathbf{x}_j^*), \quad \mathbf{x}_j^* \in \arg \min_{\mathbf{x} \in \mathcal{F}} f_j(\mathbf{x}).$$


As coordenadas podem vir de decisões diferentes; por isso, $\mathbf{u}$ pode não ser atingível.

Ponto nadir ou solução antiutópica

Reúne os piores valores de cada objetivo observados apenas na fronteira:

$$\tilde{u}_j = \max\{y_j : \mathbf{y} \in \mathcal{Y}^*\}.$$

Ponto ideal e ponto nadir delimitam a faixa de compromissos



Quando as preferências entram no processo?

As abordagens se distinguem pelo momento em que o decisor informa o que considera mais desejável.

A priori
antes da otimização

Progressiva
durante a otimização

A posteriori
depois da otimização

A pergunta que muda

- **A priori:** quais preferências devem guiar a busca?
- **Progressiva:** o que aprendemos e para onde avançar agora?
- **A posteriori:** qual compromisso escolher entre os encontrados?

A priori: as preferências guiam a otimização

O decisor informa suas preferências **antes** da execução, por meio por exemplo de pesos.

preferências → otimização → solução

Vantagem

A busca se concentra diretamente na região considerada mais relevante e normalmente retorna uma ou poucas soluções.

Cuidado

O decisor precisa expressar as trocas entre objetivos antes de conhecer os compromissos realmente disponíveis.

Exemplo: soma ponderada com pesos previamente definidos para custo, desvio de SiO_2 e desvio de Al_2O_3 .

Progressiva: decisão e otimização evoluem juntas

A participação do decisor ocorre em ciclos. O algoritmo apresenta resultados parciais; o decisor avalia esses resultados e orienta a próxima busca.

otimizar → avaliar → ajustar preferências → repetir

Vantagem

O decisor aprende sobre o problema e pode revisar suas preferências sem exigir que toda a fronteira seja explorada.

Cuidado

O processo exige interação frequente e pode ser demorado quando cada nova otimização possui custo computacional elevado.

Exemplo no case: após observar algumas composições, a Cassotis pode solicitar menor custo ou maior proximidade dos alvos de qualidade.

A posteriori: primeiro geramos, depois escolhemos

O algoritmo busca uma aproximação representativa da fronteira sem receber uma preferência. O decisor escolhe **depois** de visualizar os compromissos encontrados.

otimização → fronteira aproximada → escolha

Vantagem

Oferece uma visão ampla das trocas e permite comparar alternativas antes de assumir uma preferência definitiva.

Cuidado

Gerar uma fronteira bem convergida e diversificada pode exigir maior esforço computacional e mecanismos de manutenção da diversidade.

No case da Cassotis: primeiro são geradas composições eficientes de pilhas; depois, custo e qualidade são analisados para apoiar a escolha.

Literatura básica e materiais do case

- S. S. Rao, *Engineering Optimization: Theory and Practice*, 4ª ed., Wiley, 2009.
- K. Miettinen, *Nonlinear Multiobjective Optimization*, Springer, 1998.
- K. Deb, *Multi-Objective Optimization Using Evolutionary Algorithms*, Wiley, 2001.
- C. A. Coello Coello, “Theoretical and Numerical Constraint-Handling Techniques Used with Evolutionary Algorithms”, *Computer Methods in Applied Mechanics and Engineering*, 191, p. 1245–1287, 2002.