

Teoria da Decisão

Método da Soma Ponderada

Profa. Luiza Bernardes Real

luizabernardesreal@gmail.com

Universidade Federal de Minas Gerais
Escola de Engenharia
Graduação em Engenharia de Sistemas

Por que otimização multiobjetivo?

Situação típica

Na prática, quase todo problema real tem **múltiplos critérios conflitantes**:

- Custo vs. qualidade
- Velocidade vs. segurança
- Lucro vs. impacto ambiental


O dilema

Quando há conflito, pode não existir uma solução que seja a melhor em **todos** os critérios ao mesmo tempo.

Melhorar um objetivo geralmente piora outro.

O que buscamos?

O conjunto de soluções de **compromisso** (trade-off): a **fronteira de Pareto**.



Solução Pareto-ótima: recapitulação rápida

Definição intuitiva

Uma solução $\mathbf{x}^*$ é **Pareto-ótima** se **não existe** outra solução viável que seja ao mesmo tempo melhor em pelo menos um objetivo e não pior em todos os outros.

Dominância

$\mathbf{x}$ **domina** $\mathbf{y}$ se:

- $f_i(\mathbf{x}) \leq f_i(\mathbf{y})$ para todo i , e
- $f_j(\mathbf{x}) < f_j(\mathbf{y})$ para algum j .

Pareto-ótimas = não dominadas em todo o conjunto viável.

Consequência prática

Em problemas contínuos, pode haver **infinitas** soluções Pareto-ótimas.

Os métodos escalares geram **uma de cada vez**, variando parâmetros.

Problema de otimização multiobjetivo

Formulação geral (P_0)

$$\min_{\mathbf{x} \in \mathcal{F}} \mathbf{f}(\mathbf{x}), \quad \mathbf{f} : \mathcal{X} \subseteq \mathbb{R}^n \longrightarrow \mathbb{R}^m.$$
$$\mathcal{F} = \left\{ \mathbf{x} \in \mathcal{X} : \begin{array}{ll} g_i(\mathbf{x}) \leq 0, & i = 1, \dots, p, \\ h_j(\mathbf{x}) = 0, & j = 1, \dots, q \end{array} \right\}.$$

- n variáveis de decisão; m objetivos a minimizar.
- $\mathcal{X}$: domínio das variáveis; $\mathcal{F}$: conjunto viável.

Do espaço de decisão ao espaço dos objetivos

$$\mathcal{Y} = \mathbf{f}(\mathcal{F}) = \{\mathbf{f}(\mathbf{x}) : \mathbf{x} \in \mathcal{F}\}.$$

A geometria dessa imagem afeta quais compromissos os métodos escalares recuperam.

Métodos escalares: ideia central

Estratégia geral

Transformar o problema **multiobjetivo** em um (ou vários) problemas **mono-objetivo**, variando parâmetros para explorar a fronteira de Pareto.

1. Método da soma ponderada (*weighted-sum*)
2. Método ϵ -restrito

Método da soma ponderada (*weighted-sum*)

Ideia

Combinar os objetivos em uma soma e resolver um problema mono-objetivo.


Formulação (P_w)

$$\begin{aligned} \min_{\mathbf{x}} \quad & \mathbf{w}^T \mathbf{f}(\mathbf{x}) = \sum_{i=1}^m w_i f_i(\mathbf{x}) \\ \text{sujeito a} \quad & g_i(\mathbf{x}) \leq 0, & i = 1, \dots, p, \\ & h_j(\mathbf{x}) = 0, & j = 1, \dots, q, \\ & \mathbf{x} \in \mathcal{X}. \end{aligned}$$

Os pesos são parâmetros: $w_i \geq 0$ e $\sum_{i=1}^m w_i = 1$.

- Os pesos definem a importância relativa **nas escalas adotadas**.

Uma busca escalar, vários desempenhos



O que guardar?

A solução, os pesos e **todos os desempenhos originais**. O valor da soma, sozinho, não explica os ganhos e as perdas entre objetivos.

- Multiplicar todos os pesos por uma constante positiva não muda os minimizadores.
- Por isso, somar 1 é uma convenção útil, não uma exigência matemática.

Por que normalizar os objetivos?

Problema de escala

Se os objetivos têm **magnitudes muito diferentes**, os pesos perdem significado: o objetivo de maior magnitude domina a soma, independentemente dos w_i .

Exemplo concreto

$$f_1 \in [0, 5000] \quad \text{vs.} \quad f_2 \in [0, 2]$$

Mesmo com $w_1 = w_2 = 0,5$, a soma é dominada por f_1 .

A solução fica “enviesada” para minimizar f_1 .

Solução: normalização

Reescalar cada objetivo para $[0, 1]$ antes de combinar.

Após normalizar, os pesos têm **interpretação uniforme**: w_i é de fato a importância relativa de f_i .

Conexão com a Cassotis

Combinaremos custo em R\$ e desvios quadráticos de qualidade em p.p.². Mesmo os dois objetivos de qualidade podem ter amplitudes diferentes.

Normalização: fórmula

Normalização (minimização)

$$\bar{f}_i(\mathbf{x}) = \frac{f_i(\mathbf{x}) - \min_{\mathbf{x} \in \mathcal{F}} f_i(\mathbf{x})}{\max_{\mathbf{x} \in \mathcal{F}} f_i(\mathbf{x}) - \min_{\mathbf{x} \in \mathcal{F}} f_i(\mathbf{x})}$$

Normalização (maximização)

$$\bar{f}_i(\mathbf{x}) = \frac{\max_{\mathbf{x} \in \mathcal{F}} f_i(\mathbf{x}) - f_i(\mathbf{x})}{\max_{\mathbf{x} \in \mathcal{F}} f_i(\mathbf{x}) - \min_{\mathbf{x} \in \mathcal{F}} f_i(\mathbf{x})}$$

Exemplo ilustrativo: enunciado

Problema biobjetivo

Variável de decisão $x \in [0, 1]$:

$$\min f_1(x) = 5000x^2 \quad \min f_2(x) = 2(1 - x)$$

- Cada x gera um ponto $(f_1(x), f_2(x))$ no espaço objetivo;
- Ao variar x em $[0, 1]$, obtemos uma curva — a fronteira de Pareto (pois f_1 é crescente e f_2 é decrescente: nenhum ponto domina outro);
- Escalas muito diferentes: $f_1 \in [0, 5000]$, $f_2 \in [0, 2]$.

Questão

Como representar e comparar esses objetivos de forma equilibrada?

Problema de escala no espaço original

Com $w_1 = w_2 = 0,5$:


$$F(x) = 2500x^2 + 1 - x.$$

$$F'(x) = 5000x - 1 = 0$$

$$x^* = 0,0002.$$

$$f_1(x^*) = 0,0002.$$

$$f_2(x^*) = 1,9996.$$



Interpretação

O resultado fica muito próximo do mínimo de f_1 . O ponto vermelho está praticamente sobre o extremo superior da curva.

Cálculo dos extremos para normalização

Para $f_1(x) = 5000x^2$

$$f_1^{\min} = 0 \quad \text{em } x = 0 \quad f_1^{\max} = 5000 \quad \text{em } x = 1$$

Para $f_2(x) = 2(1 - x)$

$$f_2^{\min} = 0 \quad \text{em } x = 1 \quad f_2^{\max} = 2 \quad \text{em } x = 0$$

Aplicando a normalização

Como ambos são de minimização:

$$\bar{f}_i(x) = \frac{f_i(x) - f_i^{\min}}{f_i^{\max} - f_i^{\min}}$$

Normalização de f_1

$$\bar{f}_1(x) = \frac{5000x^2 - 0}{5000 - 0} = x^2$$

Normalização de f_2

$$\bar{f}_2(x) = \frac{2(1-x) - 0}{2 - 0} = 1 - x$$

- Agora: $\bar{f}_1, \bar{f}_2 \in [0, 1]$ — mesma escala.
- A fronteira normalizada é dada por $(\bar{f}_1, \bar{f}_2) = (x^2, 1 - x)$.

Fronteira no espaço normalizado: equação explícita


De $\bar{f}_1 = x^2$ obtemos $x = \sqrt{\bar{f}_1}$.

Substituindo em $\bar{f}_2 = 1 - x$:

$$\bar{f}_2 = 1 - \sqrt{\bar{f}_1}$$


Extremos normalizados

$$x = 0 \Rightarrow (\bar{f}_1, \bar{f}_2) = (0, 1) \quad x = 1 \Rightarrow (\bar{f}_1, \bar{f}_2) = (1, 0)$$



Comparação: original vs. normalizado

Objetivos originais




$$\min 2500x^2 + 1 - x$$

$$x^* = 0,0002$$

$$f_1(x^*) = 0,0002$$

$$f_2(x^*) = 1,9996$$

Objetivos normalizados



$$\min 0,5x^2 + 0,5(1 - x)$$

$$x^* = 0,5$$

$$f_1(x^*) = 2500$$

$$f_2(x^*) = 1$$

Conclusão do exemplo de normalização

Resumo do procedimento

- 1 Calcular os extremos (min e max) de cada objetivo sobre $\mathcal{F}$;
- 2 Aplicar a fórmula de normalização $\Rightarrow$ todos os $\bar{f}_i \in [0, 1]$;
- 3 Trabalhar com os objetivos normalizados no método da soma ponderada.

Mensagem principal

A normalização **não altera** o trade-off entre objetivos — apenas remove o viés de escala, tornando os pesos w_i interpretáveis como preferências reais.

Interpretação geométrica: a iso-curva

No caso de dois objetivos:

$$\min_{\mathbf{x}} w_1 \bar{f}_1(\mathbf{x}) + w_2 \bar{f}_2(\mathbf{x})$$

Fixando o valor da soma em c_0 :

$$w_1 \bar{f}_1 + w_2 \bar{f}_2 = c_0$$

Para $w_2 > 0$, isolando $\bar{f}_2$ (com $C = c_0/w_2$):

$$\bar{f}_2 = -\frac{w_1}{w_2} \bar{f}_1 + C$$


No espaço de objetivos, essa equação define uma **família de retas paralelas**:

- inclinação $-w_1/w_2$ (determinada pelos pesos — **fixa**)
- intercepto C (varia ao deslocar a reta)

Minimizar a soma ponderada = deslocar a reta até o menor C que ainda toca a fronteira.


O espaço de objetivos

- Cada ponto sobre a curva verde é uma solução Pareto-ótima.
- Queremos encontrar **qual** ponto é selecionado pela soma ponderada.




Deslizando a iso-curva: C grande

- Iso-curva com $w_1 = w_2 = 0,5$.
- C grande: reta **acima** da fronteira — nenhum ponto viável satisfaz essa soma.
- Precisamos **reduzir** C até tocar a fronteira.




A iso-curva tangente: solução ótima

- Reduzimos C até a reta **tocar** a fronteira de Pareto.
- O ponto de tangência é a **solução ótima** para esses pesos.
- Qualquer C menor não intersecta a fronteira.




Efeito dos pesos: $w_1 \gg w_2$

- $w_1 = 0,8$, $w_2 = 0,2$
- A reta fica mais **íngreme** ($-w_1/w_2 = -4$).
- Solução desloca para **menor** $\bar{f}_1$: minimizamos mais $\bar{f}_1$.




Efeito dos pesos: $w_2 \gg w_1$

- $w_1 = 0,2$, $w_2 = 0,8$
- A reta fica mais **suave** ($-w_1/w_2 = -0,25$).
- Solução desloca para **me-nor** $\bar{f}_2$: minimizamos mais f_2 .



Síntese: pesos controlam a solução



Conclusão

Variar os pesos w_1 , w_2 muda a **inclinação** da iso-curva e, pode mudar o ponto selecionado na fronteira de Pareto — explorando diferentes soluções de compromisso.

Exemplo de Schaffer


Problema

$$\min \mathbf{f} = \begin{cases} f_1(x) = x^2 \\ f_2(x) = (x - 2)^2 \end{cases} \quad x \in [0, 2]$$

- (a) Esboce o conjunto solução no espaço de decisão.
- (b) Aplique as condições de suficiência ao problema ponderado e mostre que as soluções de (a) são Pareto-ótimas.
- (c) Obtenha amostras da fronteira Pareto-ótima para diferentes pesos.

Item (a) — Análise das funções objetivo

- $f_1(x) = x^2$: estritamente **crescente** em $[0, 2]$
- $f_2(x) = (x-2)^2$: estritamente **decrecente** em $[0, 2]$
- Funções monótonas em sentidos opostos: nenhum ponto domina outro.
- Portanto: $\mathcal{X}_E = [0, 2]$ (todo o domínio é eficiente).



Condições de suficiência: recapitulação

Condição necessária

Se x^* é mínimo, então $f'(x^*) = 0$.

Todo mínimo é ponto crítico — mas nem todo ponto crítico é mínimo.

Condição suficiente

Se $f'(x^*) = 0$ e $f''(x^*) > 0$, então x^* é mínimo local (global, se f convexa).

A curvatura positiva “fecha o argumento”: transforma candidato em solução confirmada.

Em resumo

$$f'(x^*) = 0 \text{ e } f''(x^*) > 0 \implies x^* \text{ é mínimo.}$$

Conexão com Pareto-otimalidade

Resultado

Se x^* **minimiza globalmente** a soma ponderada $F(x) = \sum_i w_i f_i(x)$ com $w_i > 0$ para todo i , então x^* é **Pareto-ótimo**.

Prova por contradição

Suponha que x^* **não** seja Pareto-ótimo.

Então existe $\tilde{x} \in \mathcal{F}$ que **domina** x^* , ou seja:

$$f_i(\tilde{x}) \leq f_i(x^*) \quad \forall i \quad \text{e} \quad f_j(\tilde{x}) < f_j(x^*) \quad \text{para algum } j.$$

Como todos os pesos são positivos ($w_i > 0$), somando:

$$F(\tilde{x}) = \sum_i w_i f_i(\tilde{x}) < \sum_i w_i f_i(x^*) = F(x^*).$$

Isso contradiz a hipótese de que x^* minimiza F .



Item (b) — Problema ponderado e condição de suficiência

Para pesos $w_1, w_2 > 0$ com $w_1 + w_2 = 1$:

$$\min_{x \in [0,2]} F(x) = w_1 x^2 + w_2 (x - 2)^2 = x^2 - 4w_2 x + 4w_2$$

(usando $w_1 + w_2 = 1$ para simplificar)

Condição de 1ª ordem:

$$F'(x) = 2x - 4w_2 = 0 \quad \Rightarrow \quad \boxed{x^* = 2w_2}$$

Condição de 2ª ordem (suficiência):

$$F''(x) = 2 > 0 \quad \Rightarrow \quad x^* \text{ é mínimo global.}$$

Conclusão

Para $0 < w_2 < 1$, obtemos todos os pontos interiores $0 < x^* < 2$.

- Os extremos $x = 0$ e $x = 2$ são obtidos com $w_2 = 0$ e $w_2 = 1$.
- Neste exemplo, eles também são eficientes, como mostra a análise de (a).
- Com $w_2 \in [0, 1]$, a família de problemas recupera toda a fronteira.

Item (c) — Amostras da fronteira Pareto-ótima

Substituindo $x^* = 2w_2$:

$$f_1^* = 4w_2^2 \quad f_2^* = 4w_1^2$$

w_1	w_2	x^*	f_1^*	f_2^*
0,90	0,10	0,20	0,04	3,24
0,75	0,25	0,50	0,25	2,25
0,50	0,50	1,00	1,00	1,00
0,25	0,75	1,50	2,25	0,25
0,10	0,90	1,80	3,24	0,04

Equação da fronteira no espaço dos objetivos


Eliminando x entre $f_1 = x^2$ e $f_2 = (x - 2)^2$:

$$x = \sqrt{f_1} \Rightarrow f_2 = \left(\sqrt{f_1} - 2\right)^2 = f_1 - 4\sqrt{f_1} + 4$$

Essa curva descreve **todos** os pares (f_1, f_2) atingíveis ao variar $x \in [0, 2]$ — ou seja, a fronteira de Pareto no espaço dos objetivos.

Fronteira Pareto-ótima do exemplo de Schaffer

- Fronteira no espaço (f_1, f_2) , ligando $(0, 4)$ a $(4, 0)$.
- Pontos vermelhos: amostras obtidas variando os pesos.
- Neste exemplo, pesos distintos geram decisões distintas; o espaçamento no espaço dos objetivos não é uniforme.



Síntese do exemplo

- (a) $\mathcal{X}_E = [0, 2]$
- (b) $F''(x) = 2 > 0$ confirma mínimo global para qualquer $w_i > 0$
- (c) Fronteira: $f_2 = f_1 - 4\sqrt{f_1} + 4$

Gerando a fronteira em problemas lineares

Estratégia para um problema biobjetivo

- 1 Encontrar os dois extremos eficientes.
- 2 Escolher pesos cuja iso-curva seja paralela ao segmento entre eles.
- 3 Resolver o problema ponderado e verificar se surge um ponto abaixo desse segmento.
- 4 Se houver melhora estrita, subdividir e repetir.

O que o procedimento procura?

Os vértices da fronteira. Entre vértices adjacentes, segmentos inteiros podem ser eficientes. A garantia pressupõe resolução global dos subproblemas.

Algoritmo recursivo: passos

Passo 1: Resolver individualmente cada objetivo:

$$\mathbf{z}_i = \arg \min f_i(\mathbf{x}), \quad \mathbf{x} \in \mathcal{F}$$

Passo 2: Calcular os pesos derivados dos extremos:

$$\lambda_1 = f_2(\mathbf{z}_1) - f_2(\mathbf{z}_2) \quad \lambda_2 = f_1(\mathbf{z}_2) - f_1(\mathbf{z}_1)$$

Passo 3: Resolver o problema ponderado:

$$\mathbf{z} = \arg \min \lambda_1 f_1(\mathbf{x}) + \lambda_2 f_2(\mathbf{x}), \quad \mathbf{x} \in \mathcal{F}$$

Passo 4: Repetir os passos 2–3 para os pares $(\mathbf{z}_1, \mathbf{z})$ e $(\mathbf{z}, \mathbf{z}_2)$ recursivamente.

Problema exemplo biobjetivo linear

Problema

$$\min f_1(x, y) = x + 3y \quad \min f_2(x, y) = 3x + y$$

$$\text{s.a. } x + 2y \geq 4, \quad 2x + y \geq 4, \quad x \leq 4, \quad y \leq 4, \quad x, y \geq 0$$

- Objetivos lineares e simétricos (f_1 penaliza mais y , f_2 penaliza mais x);
- Região viável: polígono convexo;
- Objetivo: gerar a fronteira de Pareto pelo algoritmo recursivo.

Passo 1 — Otimizar cada objetivo

Minimizar $f_1 = x + 3y$


Solução: $\mathbf{z}_1 = (4, 0)$

$$f_1(\mathbf{z}_1) = 4, \quad f_2(\mathbf{z}_1) = 12$$

Minimizar $f_2 = 3x + y$

Solução: $\mathbf{z}_2 = (0, 4)$

$$f_1(\mathbf{z}_2) = 12, \quad f_2(\mathbf{z}_2) = 4$$



Observação

$\mathbf{z}_1$ minimiza f_1 mas tem f_2 alto. $\mathbf{z}_2$ minimiza f_2 mas tem f_1 alto. São os **extremos** da fronteira de Pareto.

Passos 2 e 3 — Calcular pesos e resolver o problema ponderado

Passo 2 — Pesos:

$$\lambda_1 = f_2(\mathbf{z}_1) - f_2(\mathbf{z}_2) = 12 - 4 = 8$$

$$\lambda_2 = f_1(\mathbf{z}_2) - f_1(\mathbf{z}_1) = 12 - 4 = 8$$

Passo 3 — Problema ponderado:

$$\min 8f_1 + 8f_2 = 8(x + 3y) + 8(3x + y) = 32(x + y)$$

Equivalente a $\min x + y$ (dividindo por 32).

Solução no vértice:


$$\mathbf{z} = \left(\frac{4}{3}, \frac{4}{3}\right) \quad f_1(\mathbf{z}) = f_2(\mathbf{z}) = \frac{16}{3} \approx 5,3$$

Resultado


$\mathbf{z}$ é um novo ponto Pareto-ótimo **entre** $\mathbf{z}_1$ e $\mathbf{z}_2$.

Três vértices e dois segmentos eficientes

Espaço das variáveis



Espaço dos objetivos



Ponto	(x, y)	f_1	f_2
z_1	$(4, 0)$	4	12
z	$(4/3, 4/3)$	$16/3 \approx 5,3$	$16/3 \approx 5,3$
z_2	$(0, 4)$	12	4

Passo 4 — Recursão: subdividir e repetir

Sub-problema A: entre z_1 e z

$$\lambda_1^A = 12 - \frac{16}{3} = \frac{20}{3} \quad \lambda_2^A = \frac{16}{3} - 4 = \frac{4}{3}$$

Sub-problema B: entre z e z_2

$$\lambda_1^B = \frac{16}{3} - 4 = \frac{4}{3} \quad \lambda_2^B = 12 - \frac{16}{3} = \frac{20}{3}$$

Critério de parada

Se o novo ponto encontrado **coincide** com um dos extremos do subintervalo, não há mais vértices Pareto-ótimos naquele trecho — a recursão para.

Método da soma ponderada: discussão

Vantagens

- Simples de implementar;
- Preserva a estrutura de restrições do problema original;
- Compatível com qualquer método de otimização mono-objetivo (programação matemática, metaheurísticas etc.).

Limitações


- Pode deixar de recuperar soluções eficientes não suportadas; uma varredura finita também pode deixar lacunas na parte suportada;
- Diferentes pesos podem levar à **mesma** solução eficiente (pesos redundantes).

Limitação: não-convexidade

Eficiente não significa alcançável

O trecho laranja é Pareto-ótimo, mas está acima do segmento PQ . Nenhuma soma com pesos não negativos, não todos nulos, o seleciona.

- Para $3f_1 + 4f_2$, P e Q empatam em 11.
- E tem soma 12,3: perde para ambos.
- Girar a reta não recupera esse trecho.



Verde: trechos suportados. Laranja: trecho não suportado.

Limitação: pesos redundantes

Pesos diferentes, mesmo ótimo

As três retas têm inclinações diferentes, mas apoiam a região viável no mesmo vértice $B = (1, 1)$.

$$\mathbf{w}^{(1)} = \left(\frac{1}{3}, \frac{2}{3}\right),$$


$$\mathbf{w}^{(2)} = \left(\frac{1}{2}, \frac{1}{2}\right),$$

$$\mathbf{w}^{(3)} = \left(\frac{2}{3}, \frac{1}{3}\right).$$

Consequência

Mais pesos não garantem mais soluções distintas nem distribuição uniforme na fronteira.

Neste exemplo, B é o ótimo único para todo $1/4 < w_1 < 3/4$, com $w_2 = 1 - w_1$.



Da soma ponderada ao VNS/GVNS da Cassotis

Três objetivos; o mesmo conjunto viável

$$\min_{\mathbf{x} \in \mathcal{F}} w_1 \bar{f}_1(\mathbf{x}) + w_2 \bar{f}_2(\mathbf{x}) + w_3 \bar{f}_3(\mathbf{x}).$$

f_1 : custo; f_2 : desvios quadráticos de SiO_2 ; f_3 : desvios quadráticos de Al_2O_3 .

- 1 Fixar referências da Entrega 1 e escolher pesos com $w_1 + w_2 + w_3 = 1$. Incluir combinações com os três pesos positivos.
- 2 Executar a busca para cada vetor; registrar pesos, semente e desempenhos originais.
- 3 Reunir soluções viáveis, retirar duplicatas e filtrar dominância em **três objetivos**, antes das projeções.

Preferência não flexibiliza restrições

Reduzir o peso da sílica permite aceitar maior desvio do alvo **dentro dos limites**. Massa, disponibilidade, elegibilidade e faixas de qualidade continuam obrigatórias.

O que a busca computacional permite afirmar?

Garantia matemática

Pesos positivos e ótimo global viável garantem Pareto-otimalidade.

Um ótimo local não tem necessariamente essa propriedade em todo $\mathcal{F}$.

Resultado de uma metaheurística

O VNS/GVNS retorna a melhor solução encontrada no orçamento disponível.

Repetir com outras sementes avalia variabilidade, mas não prova otimalidade global.

Ao apresentar os resultados do case

Use “soluções não dominadas entre as encontradas”.

Atividade rápida: interpretar uma mudança de pesos

Duas soluções viáveis têm desempenhos **já normalizados**:

$$\bar{f}(A) = (0,2; 0,8; 0,4), \quad \bar{f}(B) = (0,5; 0,3; 0,4).$$

- 1 Alguma domina a outra?
- 2 Qual tem menor soma para $\mathbf{w} = (0,6; 0,2; 0,2)$?
- 3 E para $\mathbf{w} = (0,2; 0,6; 0,2)$? O que mudou?

Atividade rápida: interpretar uma mudança de pesos

Duas soluções viáveis têm desempenhos **já normalizados**:

$$\bar{f}(A) = (0,2; 0,8; 0,4), \quad \bar{f}(B) = (0,5; 0,3; 0,4).$$

- 1 Alguma domina a outra?
- 2 Qual tem menor soma para $\mathbf{w} = (0,6; 0,2; 0,2)$?
- 3 E para $\mathbf{w} = (0,2; 0,6; 0,2)$? O que mudou?

Conferência

São incomparáveis. No primeiro caso, $S(A) = 0,36 < S(B) = 0,44$. No segundo, $S(B) = 0,36 < S(A) = 0,60$. A preferência mudou; as soluções e seus desempenhos permaneceram iguais.

Síntese da aula

Soma ponderada: o que vimos

- 1 Transformação de multiobjetivo em mono-objetivo via pesos w_i ;
- 2 Normalização: explicitar as faixas usadas para comparar escalas;
- 3 Interpretação geométrica: iso-curvas deslizando até tocar a fronteira;
- 4 Algoritmo recursivo para problemas lineares;
- 5 Limitação: não recupera soluções eficientes não suportadas.

Para onde vamos?

O **método ϵ -restrito** contorna a limitação de não-convexidade ao transformar objetivos em restrições — ao custo de potenciais infacibilidades.

Literatura Especializada



Y. Collette, P. Siarry, Multiobjective Optimization: Principles and Case Studies, ser. Decision Engineering, Springer, 2003.



V. Chankong, Y. Haimes, Multiobjective decision making: Theory and methodology, 1st ed., Dover Publications, 2008.



R. H. C. Takahashi, Otimização Escalar e Vetorial, 2007. Disponível em: <http://www.mat.ufmg.br/~taka/>



J.-S. Roger Jang, C. T. Sun, E. Mizutani, Neuro-Fuzzy and Soft Computing, Matlab Curriculum Series, Prentice Hall, 1997.



P. Prodanovic and S. P. Simonovic, Fuzzy Compromise Programming for Group Decision Making, IEEE Trans. Syst. Man Cybern., 33:3, pp. 358–365, 2003.



L.S. Batista, Notas de Aula.