

Teoria da Decisão

Método ε -restrito

Profa. Luiza Bernardes Real

luizabernardesreal@gmail.com

Universidade Federal de Minas Gerais
Escola de Engenharia
Graduação em Engenharia de Sistemas

Revisão: método da soma ponderada

Ideia central

$$\min_{\mathbf{x} \in \mathcal{F}} \sum_{i=1}^m w_i f_i(\mathbf{x}), \quad w_i \geq 0, \quad \sum_i w_i = 1$$

- Cada vetor $\mathbf{w}$ gera **uma solução eficiente**;
- Variando $\mathbf{w} \Rightarrow$ exploramos a fronteira de Pareto;

Pontos importantes

- Necessidade de **normalização**;
- Funciona bem se a fronteira for **convexa**;
- Pode não encontrar soluções em regiões **não-convexas**.

Limitação-chave

Nem toda solução Pareto-ótima pode ser obtida via soma ponderada.

Quanto atraso podemos aceitar?

Cinco planos viáveis; queremos minimizar **custo e atraso**.

Plano	Custo (R\$)	Atraso (h)
A	1000	10
E	1200	9
B	1400	4
D	1700	7
C	2000	0

Uma pergunta operacional

Qual é o plano de menor custo com **no máximo 9 horas de atraso**?

Quanto atraso podemos aceitar?

Cinco planos viáveis; queremos minimizar **custo e atraso**.

Plano	Custo (R\$)	Atraso (h)
A	1000	10
E	1200	9
B	1400	4
D	1700	7
C	2000	0

Uma pergunta operacional

Qual é o plano de menor custo com **no máximo 9 horas de atraso**?

Primeiro filtrar, depois otimizar

A não atende ao limite. Entre E, B, D e C, o menor custo é o de **E**.

A mesma decisão, duas perguntas

Soma ponderada

$$\min_{\mathbf{x} \in \mathcal{F}} w_1 \bar{f}_1(\mathbf{x}) + w_2 \bar{f}_2(\mathbf{x}).$$

Qual solução tem a menor soma, nas escalas e pesos escolhidos?

Os pesos são parâmetros; os desempenhos resultam da solução.

Método ε -restrito

$$\min_{\mathbf{x} \in \mathcal{F}} f_1(\mathbf{x}) \quad \text{s.a. } f_2(\mathbf{x}) \leq \varepsilon.$$

Qual solução tem menor f_1 respeitando o limite para f_2 ?

ε é um parâmetro com a mesma unidade de f_2 .

Não se exige $f_2 = \varepsilon$. Uma solução pode ficar abaixo do limite.

Definir os conjuntos antes de mudar o problema

Problema original: todos os objetivos a minimizar

$$\min_{\mathbf{x}} \mathbf{f}(\mathbf{x}) \in \mathbb{R}^m, \mathbf{x} \in \mathcal{F}$$

$$\mathbf{f} : \mathcal{X} \subset \mathbb{R}^n \mapsto \mathcal{Y} \subset \mathbb{R}^m$$

$$\mathcal{F} = \begin{cases} g_i(\mathbf{x}) \leq 0; & i = 1, \dots, p \\ h_j(\mathbf{x}) = 0; & j = 1, \dots, q \\ \mathbf{x} \in \mathcal{X} \end{cases}$$

Escolher um objetivo; restringir os demais

Escolhemos f_1 como principal, apenas para fixar a notação.



Novo subproblema

$$P_\varepsilon : \min_{\mathbf{x} \in \mathcal{F}_\varepsilon} f_1(\mathbf{x}), \quad \mathcal{F}_\varepsilon = \{\mathbf{x} \in \mathcal{F} : f_k(\mathbf{x}) \leq \varepsilon_k, k = 2, \dots, m\}.$$

- $\varepsilon = (\varepsilon_2, \dots, \varepsilon_m)$: vetor de limites fixados antes da busca.
- $\mathcal{F}_\varepsilon \subseteq \mathcal{F}$: mantemos todas as restrições originais e acrescentamos $m - 1$ limites.
- Outro objetivo pode ser o principal. Essa escolha muda os subproblemas e a amostragem finita.


Para um objetivo a **maximizar**, um requisito mínimo tem direção $f_k(\mathbf{x}) \geq \varepsilon_k$.

Primeiro, o recorte com dois objetivos



O limite recorta o espaço dos objetivos

- Faixa colorida: desempenhos que atendem ao atraso máximo de 9 h.
- Só os pontos dentro da faixa colorida representam soluções viáveis desta instância.
- Entre os pontos aceitos, procuramos o mais à esquerda: menor custo.



Atividade: apertar o limite muda o plano?

Plano	R\$	h
A	1000	10
E	1200	9
B	1400	4
D	1700	7
C	2000	0

Minimizem o custo para:

$$\varepsilon \in \{10, 9, 8, 7, 4, 3, 0, -1\} h.$$

- 1 Quais planos atendem a cada limite?
- 2 Qual é escolhido? Qual seu atraso efetivo?
- 3 Quando há repetição? Quando não há solução?

Registrem o par (custo, atraso), além do nome do plano.

Conferência: limites diferentes, soluções repetidas

ε (h)	Ótimo	Custo (R\$)	Atraso efetivo (h)
10	A	1000	10
9	E	1200	9
8, 7, 4	B	1400	4
3, 0	C	2000	0
-1	Subproblema inviável		

- Em $\varepsilon = 8$, B tem **folga** de 4 h; o limite não precisa ser atingido.
- D nunca vence: B o domina, pois é mais barato e tem menos atraso.
- Uma malha $\{10, 8, 6, 4, 2, 0\}$ perderia E. O passo da varredura importa.

Apertar o limite tem um preço

1. Se $\varepsilon' < \varepsilon$, quem atende ao limite menor também atende ao maior:

$$f_2(\mathbf{x}) \leq \varepsilon' \Rightarrow f_2(\mathbf{x}) \leq \varepsilon \quad \Rightarrow \quad \mathcal{F}_{\varepsilon'} \subseteq \mathcal{F}_{\varepsilon}.$$

2. Minimizar sobre menos opções não melhora o menor custo possível:

$$f_1^*(\varepsilon') \geq f_1^*(\varepsilon) \quad (\text{se ambos têm ótimo global}).$$

O resultado de uma heurística pode seguir outra ordem

Com limite de 9 h, uma execução pode encontrar apenas C (R\$ 2000). Com limite de 8 h, outra pode encontrar B (R\$ 1400).

3. B também era permitido com 9 h, mas a primeira busca não o encontrou. Os mínimos verdadeiros são R\$ 1200 e R\$ 1400: continuam na ordem esperada.

A diferença vem da busca incompleta, não de uma melhora causada pelo limite.

Schaffer: agora o limite atua sobre uma variável contínua

Retomamos o exemplo da Aula 5, sem precisar de derivadas:

$$f_1(x) = x^2, \quad f_2(x) = (x - 2)^2, \quad x \in [0, 2].$$

- f_1 cresce e f_2 decresce: todo $x \in [0, 2]$ é Pareto-ótimo.
- O conjunto eficiente está no espaço de decisão; sua imagem é uma curva nos objetivos.

Subproblema

$$\min_{x \in [0, 2]} x^2 \quad \text{s.a. } (x - 2)^2 \leq \varepsilon.$$

Qual é o menor x permitido quando $\varepsilon = 1$?

Schaffer: resolver a restrição antes de minimizar


1. De onde vem a faixa útil $[0, 4]$?

$$f_2(0) = 4, \quad f_2(2) = 0.$$

Como $f_2 = (x - 2)^2$ decresce em $[0, 2]$, seus valores vão de 4 até 0. Por isso exploramos $0 \leq \varepsilon \leq 4$.

2. Resolver o limite para x :

$$\begin{aligned}(x - 2)^2 \leq \varepsilon &\iff |x - 2| \leq \sqrt{\varepsilon} \\ &\iff -\sqrt{\varepsilon} \leq x - 2 \leq \sqrt{\varepsilon} \\ &\iff 2 - \sqrt{\varepsilon} \leq x \leq 2 + \sqrt{\varepsilon}.\end{aligned}$$



Verde: $x \in [1, 2]$, permitido quando $\varepsilon = 1$.

Schaffer: intersectar com o domínio e escolher o mínimo

3. O limite permite um intervalo; o domínio permite outro:

$$\mathcal{F}_\varepsilon = [2 - \sqrt{\varepsilon}, 2 + \sqrt{\varepsilon}] \cap [0, 2].$$

4. Conferir as duas pontas, para $0 \leq \varepsilon \leq 4$:

$$0 \leq \sqrt{\varepsilon} \leq 2 \Rightarrow \underbrace{2 - \sqrt{\varepsilon} \geq 0}_{\text{ponta inferior dentro do domínio}}, \quad \underbrace{2 + \sqrt{\varepsilon} \geq 2}_{\text{ponta superior limitada pelo domínio}}.$$

$$\boxed{\mathcal{F}_\varepsilon = [2 - \sqrt{\varepsilon}, 2].}$$

5. Minimizar x^2 : ela cresce em $[0, 2]$, então escolher o menor x permitido:

$$x^* = 2 - \sqrt{\varepsilon}, \quad f_1^* = (2 - \sqrt{\varepsilon})^2, \quad f_2^* = \varepsilon.$$

Em $\varepsilon = 1$: $\mathcal{F}_\varepsilon = [1, 2]$, $x^* = 1$, $(f_1^*, f_2^*) = (1, 1)$.


Schaffer: varrer epsilon e verificar os extremos

Em $0 \leq \varepsilon \leq 4$:

$$\mathcal{F}_\varepsilon = [2 - \sqrt{\varepsilon}, 2], \quad x^* = 2 - \sqrt{\varepsilon}.$$

ε	x^*	(f_1^*, f_2^*)
4	0	(0, 4)
2	$2 - \sqrt{2}$	$(\approx 0,343, 2)$
1	1	(1, 1)
0,25	1,5	(2,25, 0,25)
0	2	(4, 0)

Reduzir ε move o ótimo de (0, 4) até (4, 0). Os extremos 0 e 4 pertencem à faixa.




Schaffer: limite não é valor que o objetivo deve assumir

Limite	Conjunto permitido $\mathcal{F}_\varepsilon$	Ótimo e explicação
$\varepsilon < 0$	Vazio: $(x - 2)^2 \geq 0$ para todo x .	Não há solução que atenda ao limite.
$0 \leq \varepsilon < 4$	$[2 - \sqrt{\varepsilon}, 2]$; o intervalo encolhe quando o limite aperta.	$x^* = 2 - \sqrt{\varepsilon}$; aqui $f_2^* = \varepsilon$.
$\varepsilon \geq 4$	$[0, 2]$: todo ponto do domínio já tem $f_2 \leq 4 \leq \varepsilon$.	Minimizar x^2 escolhe $x^* = 0$; logo $f_2^* = (0 - 2)^2 = 4$.

Folga, redundância e inviabilidade não são a mesma coisa



Objetivo principal: minimizar f_1 . **Restrição adicional:** $f_2 \leq \varepsilon$.



Folga $= \varepsilon - f_2(\mathbf{x}^*)$: o ótimo é escolhido pelo menor f_1 entre os pontos permitidos.

Redundância: $\varepsilon \geq \max_{\mathbf{x} \in \mathcal{F}} f_2(\mathbf{x})$. **Inviabilidade suficiente:** $\varepsilon < \min_{\mathbf{x} \in \mathcal{F}} f_2(\mathbf{x})$.

Dois limites simultâneos: figuras em duas dimensões




Problema inviável: os limites podem ser incompatíveis

$$\mathcal{F}_\varepsilon = \mathcal{F} \cap \{f_2 \leq \varepsilon_2\} \cap \{f_3 \leq \varepsilon_3\}.$$

Os dois limites são possíveis separadamente, mas suas regiões não se intersectam: $\mathcal{F}_\varepsilon = \emptyset$.

Provar que não existe: demonstrar a interseção vazia, enumerar exaustivamente o conjunto finito ou obter um certificado de inviabilidade de um método exato.

Não encontrar: uma heurística visitou só parte das soluções no orçamento disponível. Outras podem atender aos limites.



Algoritmo caso bicritério

Algoritmo 1: Bi-objective Epsilon-Constraint Method

Input : Objective bounds $\underline{f} \leq \bar{f}$ and increment $\delta > 0$

```
1  $P := \emptyset$ ;  
2  $\varepsilon := \bar{f}$ ;  
3 while  $\varepsilon \geq \underline{f}$  do  
4    $\mathbf{x} := \text{opt}(\mathbf{f}, \varepsilon)$ ;  
5   if  $\mathbf{x}$  is feasible then  
6     if  $\nexists \mathbf{x}' \in P$  such that  $\mathbf{x}' \succ \mathbf{x}$  then  
7        $P := P \setminus \{\mathbf{x}' \in P : \mathbf{x} \succ \mathbf{x}'\}$ ;  
8        $P := P \cup \{\mathbf{x}\}$ ;  
9     end  
10  end  
11   $\varepsilon := \varepsilon - \delta$ ;  
12 end
```

Output: Set of nondominated decision vectors among the candidates found P

O passo controla esforço e cobertura

Uma resolução para cada limite: minimizar o custo sujeito a atraso $\leq \varepsilon$.

Neste exemplo, começamos com **quatro níveis**: 10, 8, 6 e 4 horas; o passo é $\delta = 2$ h.

Limite ε (h)	10	8	6	4
Plano encontrado	A	B	B	B
Custo (R\$)	1000	1400	1400	1400
Atraso obtido (h)	10	4	4	4

- De 10 para 8 h: o plano muda; o custo sobe R\$ 400 e o atraso cai 6 h.
- De 8 para 6 e 4 h: o mesmo plano continua sendo escolhido.

Um passo menor exige mais resoluções. Ele pode revelar outros compromissos, mas também repetir soluções.

Soluções em trechos não convexos


Soma ponderada: minimizar

$$w_1 f_1 + w_2 f_2, \quad w_1, w_2 > 0.$$

As retas de nível se deslocam para valores menores até tocar o conjunto de desempenhos viáveis.


No trecho curvo ilustrado, os pontos ficam acima da reta que liga os extremos. Uma reta de nível que passa por um ponto interno deixa pelo menos um extremo com custo ponderado menor. Esse trecho não é selecionado pela soma ponderada.

ϵ -restrito: imponha $f_2 \leq \epsilon$ e minimize f_1 entre os pontos permitidos. Na figura, isso seleciona P^* , mesmo no trecho não convexo.



Escolher limites para focar uma região de interesse

- Ao fixar ε em um **valor específico**, a solução encontrada pertence a um **trecho determinado** da fronteira.
- Isso permite ao decisor **focar a busca** em regiões de interesse, sem precisar varrer toda a fronteira.
- Diferente da soma ponderada, onde o trecho explorado depende dos pesos de forma **pouco intuitiva**, aqui o controle é **direto**: escolhe-se o intervalo de f_2 desejado.



Empates em f_1 : um ótimo escalar pode ser dominado


Objetivo principal: minimizar f_1 .

Limite secundário: $f_2 \leq \varepsilon$.

Na figura, $P = (1, 3)$ e $Q = (1, 2)$ são permitidos. Ambos atingem o menor $f_1 = 1$.

$$f_1(Q) = f_1(P), \quad f_2(Q) < f_2(P).$$

Logo, Q domina P : devolver qualquer minimizador de f_1 pode devolver P .



Limites possíveis isoladamente podem ser incompatíveis juntos

Para tornar concreto o conflito visto anteriormente, considere $\mathcal{F} = \mathbb{R}^2$ e

$$f_2(\mathbf{x}) = (x_1 - 1)^2 + (x_2 - 3)^2,$$

$$f_3(\mathbf{x}) = (x_1 - 5)^2 + (x_2 - 3)^2.$$


Com $\varepsilon_2 = \varepsilon_3 = 1$, cada limite admite um disco de raio 1.

Os centros distam 4, mas a soma dos raios é 2. Portanto, os discos não se encontram:

$$\mathcal{F}_\varepsilon = \{\mathbf{x} : f_2(\mathbf{x}) \leq 1\} \cap \{\mathbf{x} : f_3(\mathbf{x}) \leq 1\} = \emptyset.$$

Não existe solução para minimizar f_1 nesses limites, independentemente da busca utilizada.

Mais objetivos implicam mais limites simultâneos a verificar.



Propriedades e limitações

- Variar os limites ε_k permite explorar diferentes compromissos entre os objetivos; limites adequados podem recuperar soluções Pareto-ótimas, com otimização global.
- O método alcança soluções em trechos não convexos da fronteira, inclusive pontos não suportados pela soma ponderada.
- Escolher um intervalo de limites permite concentrar a busca em regiões de interesse.
- Acrescentar limites pode tornar o subproblema inviável: limites possíveis isoladamente podem ser incompatíveis em conjunto.
- Um ótimo escalar pode ser dominado quando há empates no objetivo principal; o desempate adequado garante eficiência.
- Métodos exatos e heurísticas podem resolver os subproblemas, mas as garantias matemáticas exigem otimização global.

Cassotis: custo principal, dois limites de qualidade

Três desempenhos; as mesmas soluções de pilhas

f_1 : custo total (R\$); f_2 : soma dos desvios quadráticos de SiO_2 ; f_3 : soma dos desvios quadráticos de Al_2O_3 (ambos em p.p.²).

O enunciado da Entrega 2 solicita **normalização antes de fixar os limites**:

$$\min_{\mathbf{x} \in \mathcal{F}} \bar{f}_1(\mathbf{x}) \quad \text{s.a.} \quad \bar{f}_2(\mathbf{x}) \leq \varepsilon_2, \quad \bar{f}_3(\mathbf{x}) \leq \varepsilon_3.$$

- $\mathbf{x}$ codifica receitas/posições de caminhões de 2 kt nas 10 pilhas.
- $\mathcal{F}$ preserva massa exata, elegibilidade, disponibilidades globais e faixas de qualidade de cada pilha.

Limitar o desvio do alvo não substitui a faixa de qualidade

1. Calcule o desvio de cada pilha:

$$d_\ell = s_\ell(\mathbf{x}) - s_\ell^{\text{alvo}}, \quad \ell = 1, \dots, 10.$$

2. Some os quadrados dos desvios: $f_2(\mathbf{x}) = \sum_{\ell=1}^{10} d_\ell^2$.

Exemplo ilustrativo nas unidades originais

Suponha um limite para a soma: $f_2 \leq 1$ p.p.². Se a pilha 1 desvia 1 p.p. e as outras nove têm desvio zero:

$$f_2 = 1^2 + 0^2 + \dots + 0^2 = 1.$$

A soma atende ao limite, mesmo com todo o desvio em uma única pilha.

3. Verifique também cada faixa física: $s_\ell^{\min} \leq s_\ell(\mathbf{x}) \leq s_\ell^{\max}$. Se a faixa da pilha 1 só admitir 0,2 p.p. de desvio em relação ao alvo, essa pilha é inaceitável, apesar de a soma atender ao limite.

Na varredura, usamos a soma normalizada: $\bar{f}_2 \leq \varepsilon_2$. A reescala não substitui as faixas por pilha. O mesmo cuidado vale para alumina.

Dois limites: cada resolução recebe um par de valores

1. **Mantenha o custo como objetivo principal:** minimizar $f_1(\mathbf{x})$.
2. **Escolha um teto para cada desvio normalizado:**

$$\bar{f}_2(\mathbf{x}) \leq \varepsilon_2 \quad (\text{sílica}), \quad \bar{f}_3(\mathbf{x}) \leq \varepsilon_3 \quad (\text{alumina}).$$

Uma combinação define um subproblema

Com $(\varepsilon_2, \varepsilon_3) = (\frac{1}{3}, \frac{2}{3})$, buscamos o plano de menor custo que satisfaça **os dois limites simultaneamente**, além das restrições físicas.

3. **Para explorar outro compromisso, mude um ou ambos os limites.** Por exemplo, $(\frac{1}{3}, 1)$ mantém o teto da sílica e permite mais desvio de alumina.

Cada par exige uma resolução. Ela pode produzir um novo plano, repetir um plano anterior ou definir um subproblema inviável.

A malha combina cada limite de sílica com cada limite de alumina

Escolha quatro níveis ilustrativos para cada limite: 0, $\frac{1}{3}$, $\frac{2}{3}$, 1.

Limite de sílica ε_2	Limite de alumina ε_3			
	0	$\frac{1}{3}$	$\frac{2}{3}$	1
0	(0, 0)	$(0, \frac{1}{3})$	$(0, \frac{2}{3})$	(0, 1)
$\frac{1}{3}$	$(\frac{1}{3}, 0)$	$(\frac{1}{3}, \frac{1}{3})$	$(\frac{1}{3}, \frac{2}{3})$	$(\frac{1}{3}, 1)$
$\frac{2}{3}$	$(\frac{2}{3}, 0)$	$(\frac{2}{3}, \frac{1}{3})$	$(\frac{2}{3}, \frac{2}{3})$	$(\frac{2}{3}, 1)$
1	(1, 0)	$(1, \frac{1}{3})$	$(1, \frac{2}{3})$	(1, 1)

Cada célula é uma resolução: 4 linhas $\times$ 4 colunas = 16 subproblemas.

Testar apenas limites iguais usa somente quatro células da diagonal. Deixa de testar combinações como $(\frac{1}{3}, 1)$: sílica mais restritiva e alumina mais permissiva.

Atividade: limites possíveis isoladamente podem ser incompatíveis

Três soluções viáveis didáticas:

Solução	$\bar{f}_1$	$\bar{f}_2$	$\bar{f}_3$
U	0,2	0,8	0,2
V	0,5	0,2	0,8
W	0,6	0,4	0,4

Assumam que são as únicas soluções disponíveis. Minimizem custo para os pares:

$$(\varepsilon_2, \varepsilon_3) \in \{(0,8; 0,8), (0,4; 0,4), (0,2; 0,2)\}.$$

Atividade: limites possíveis isoladamente podem ser incompatíveis

Três soluções viáveis didáticas:

Solução	$\bar{f}_1$	$\bar{f}_2$	$\bar{f}_3$
U	0,2	0,8	0,2
V	0,5	0,2	0,8
W	0,6	0,4	0,4

Assumam que são as únicas soluções disponíveis. Minimizem custo para os pares:

$$(\varepsilon_2, \varepsilon_3) \in \{(0,8; 0,8), (0,4; 0,4), (0,2; 0,2)\}.$$

Conferência

Respectivamente: U, W e nenhuma solução. O mínimo de cada desvio é 0,2, mas eles não podem ser atingidos juntos nesta instância.

Adaptar o VNS/GVNS: verificar também os novos limites

- 1 Antes da busca, fixe ε_2 e ε_3 . Durante esse subproblema, esses valores não mudam.
- 2 Reutilize representação, construção, N1/N2/N3, busca local e perturbação da Entrega 1.
- 3 Verifique as restrições originais e $f_2 \leq \varepsilon_2$, $f_3 \leq \varepsilon_3$. Justifique como tratar violações: rejeitar, reparar, penalizar ou priorizar soluções viáveis.
- 4 Guarde a melhor solução que respeite **todas** as restrições, mesmo que a busca visite soluções inviáveis.

Somar os excessos na escala normalizada escolhida

$$v_\varepsilon(\mathbf{x}) = \max\{0, f_2(\mathbf{x}) - \varepsilon_2\} + \max\{0, f_3(\mathbf{x}) - \varepsilon_3\}.$$

Algoritmo geral: cinco repetições e mudanças de configuração

Algoritmo 2: Protocolo de métodos escalares para uma abordagem

Input: Objetivos f , restrições g, h ; abordagem M ; lista de configurações C

Output: Conjuntos $P_1, \dots, P_5$, não dominados entre os candidatos de cada varredura

```
1 for  $r = 1, \dots, 5$  (repetições independentes) do
2    $P_r := \emptyset$ ;
3   foreach  $c \in C$  (mudar pesos ou limites) do
4     Registrar nova semente e gerar solução inicial  $\mathbf{x}_0$ ;
5     if  $M$  é soma ponderada then
6       Definir  $\mathbf{w} := c$  e formular  $P_{\mathbf{w}}$ ;
7     else
8       Definir  $(\varepsilon_2, \varepsilon_3) := c$  e formular  $P_{\varepsilon}$ ;
9     end
10    Resolver a formulação por VNS/GVNS a partir de  $\mathbf{x}_0$ ; Adicionar os candidatos viáveis a  $P_r$ ;
11  end
12  Retirar duplicatas e soluções dominadas de  $P_r$  nos três objetivos;
13 end
```

Síntese: dois caminhos para construir compromissos

	Soma ponderada	ϵ -restrito
Parâmetros	Pesos nas escalas escolhidas	Limites para objetivos secundários
Restrições	Mantém as originais	Acrescenta limites às originais
Alcance com ótimos globais	Pode perder soluções não suportadas	Pode recuperá-las com limites adequados
Cuidados	Seleção dos pesos, escalas e pesos nulos	Seleção dos limites, inviabilidade e empates

Da geração à escolha

Os métodos geram soluções de compromisso. Escolher e justificar a ação final exigirá preferências e métodos de apoio à decisão.

Próximos marcos

Data	Marco
27/09	Entrega 1
02/10	Apresentação da Parte 1
09/10	Prova 1
16/10	Entrega 2

Ligação com o trabalho

Este protocolo de experimentos prepara a Entrega 2 de 16/10.

Referências

-  Y. Collette e P. Siarry. *Multiobjective Optimization: Principles and Case Studies*. Springer, 2003.
-  V. Chankong e Y. Haimes. *Multiobjective Decision Making: Theory and Methodology*. Dover, 2008.
-  G. Mavrotas. Effective implementation of the ε -constraint method in Multi-Objective Mathematical Programming problems. *Applied Mathematics and Computation*, 213(2):455–465, 2009.
-  M. Laumanns, L. Thiele e E. Zitzler. An efficient, adaptive parameter variation scheme for metaheuristics based on the ε -constraint method. *European Journal of Operational Research*, 169(3):932–942, 2006.